

Anticipar el riesgo en capacitaciones

- SERVIR / ENAP · Trabajo Parcial de Data Mining Tools
- Ronal Sebastian Cueto Ninaja · Sebastián Alonso Yparraguirre Aquino
- Docente: Carlos Fernando Montoya Cubas · UPC · 202620
- Pregunta: ¿podemos anticipar desaprobación o retiro al inscribirse?


Avance preliminar: datos → preparación → comparación → evaluación

Problema, objetivo y datos

- Una fila = una participación; la identidad está enmascarada.
- $y=1$: DESAPROBADO o RETIRADO. $y=0$: APROBADO en la población evaluable.
- Fuente: Datos Abiertos de SERVIR, reporte dic-2025 / may-2026; ODC-By.
- Original: 83 930 filas $\times$ 20 columnas; 2 170 positivos (2,59 %).
- Para modelar: 36 681 filas / 198 ediciones con evaluación; riesgo 5,92 %.

El régimen se infiere de estados históricos; confirmar metadata antes de uso real.

EDA: el curso y la edición importan



El 10 % de las ediciones concentra 57 % del riesgo. Asociación no implica causa.

Calidad: decisiones justificadas

- Normalizar espacios, mayúsculas y variantes de escritura.
- Corregir y marcar 1 498 términos en 2015 incompatibles con inicios de 2025.
- Conservar duplicados: perfiles iguales pueden ser personas distintas.
- Conservar extremos válidos y excluir identificadores/estado de las predictoras.
- Diez entradas: perfil, tipo, modalidad, convocatoria, horas y calendario.

Correcciones y población son supuestos explícitos; se conserva trazabilidad.

Separar por edición, no por fila

- Al azar: 100 % del test comparte edición con train; 82 % tiene perfil/edición equivalente.
- Por edición: ningún grupo se comparte entre train y test.
- Train: 29 336 filas / 158 ediciones. Test: 7 345 / 40.
- Validación: cinco folds guardados dentro de train; ningún grupo cruza folds.
- 17 nombres de curso sí se comparten; cambia la composición por tipo.


Se prueban ediciones nuevas; no exclusivamente cursos nuevos ni períodos futuros.

Pipeline y modelos vistos en clase

- ColumnTransformer: mediana para numéricas; SIN_DATO + one-hot para categorías.
- StandardScaler solo en regresión logística; fit solo dentro de cada entrenamiento.
- Dummy mayoritario como baseline; logística, árbol y random forest como alternativas.
- Pesos de clase; límites de profundidad/hoja; no se remuestrea test/validación.
- PredefinedSplit respeta FOLD. Configuraciones fijadas antes de evaluar test.


Semanas 3 y 5: preprocesamiento + clasificador en un flujo reproducible.

Comparación: media y dispersión




Elegido por AP media: Random forest (0.169 ± 0.032). Desviación $\neq$ IC.

Curvas: la clase positiva es rara




AP resume precision-recall; ROC-AUC es complementaria. Estas curvas son OOF de desarrollo.

Umbral fijado antes de leer test



Umbral 0.639: máximo F1 OOF. F1 ajustada OOF tiene sesgo de selección; no es prueba independiente.

Test: aciertos y errores concretos



Detectados: 168/435 · Omitidos: 267 · Falsas alertas: 677 · Recall 38.6% · Precision 19.9%

Qué permite concluir este corte

- Test: F1 0.263; AP 0.222 frente a 0.059 del dummy.
- F1 a 0.5: 0.268. El umbral OOF no mejoró F1 en este test.
- Superar una referencia no demuestra utilidad institucional ni causalidad.
- Pocos retirados y diferencias de composición entre train/test.
- EDA inicial observó todo el dataset. Scores ponderados no calibrados.

Interpretar FP/FN y estabilidad según el propósito, como plantea la semana 6.

TF1: mejorar y validar el uso

- Confirmar régimen/fechas y encapsular limpieza desde el CSV crudo.
- Validación temporal y anidada por grupos; experimentos registrados.
- Calibración, costos de errores y capacidad real de seguimiento.
- Ampliar análisis por segmentos e interpretación sin causalidad.
- Aplicación de uso: entradas validadas, política de alertas y demo reproducible.

Evidencia: notebooks 01-04, reports/metrics, documentación y código reproducible.